

Distribuirana estimacija stanja korištenjem Belief Propagation algoritma

Završni rad prvog ciklusa studija

Berina Biberović

Distribuirana estimacija stanja
korištenjem Belief Propagation algoritma

autor

Berina Biberović

mentor

Dr Mirsad Čosović, docent

za akademsku titulu

Bakalaureat/Bachelor - Inženjer elektrotehnike,
odsjek automatika i elektronika

završni rad dostavljen

Odsjek za automatiku i elektroniku,
Elektrotehnički fakultet Sarajevo,
Univerzitet u Sarajevu,
Bosna i Hercegovina.

Septembar 2022. godine

Univerzitet u Sarajevu
Elektrotehnički fakultet
Odsjek za automatiku i elektroniku

Izjava o autentičnosti radova

Završni rad prvog ciklusa studija

Ime i prezime: Berina Biberović

Naslov rada: Distribuirana estimacija stanja korištenjem Belief Propagation algoritma

Vrsta rada: Završni rad prvog ciklusa studija

Broj stranica: 30

Potvrđujem:

- da sam pročitao/la dokumente koji se odnose na plagijarizam, kako je to definirano Statutom Univerziteta u Sarajevu, Etičkim kodeksom Univerziteta u Sarajevu i pravilima studiranja koja se odnose na I i II ciklus studija, integrirani studijski program I i II ciklusa i III ciklus studija na Univerzitetu u Sarajevu, kao i uputama o plagijarizmu navedenim na web stranici Univerziteta u Sarajevu;
- da sam svjestan/na univerzitetskih disciplinskih pravila koja se tiču plagijarizma;
- da je rad koji predajem potpuno moj, samostalni rad, osim u dijelovima gdje je to naznačeno;
- da rad nije predat, u cjelini ili djelimično, za stjecanje zvanja na Univerzitetu u Sarajevu ili nekoj drugoj visokoškolskoj ustanovi;
- da sam jasno naznačio/la prisustvo citiranog ili parafraziranog materijala i da sam se referirao/la na sve izvore;
- da sam dosljedno naveo/la korištene i citirane izvore ili bibliografiju po nekom od preporučenih stilova citiranja, sa navođenjem potpune reference koja obuhvata potpuni bibliografski opis korištenog i citiranog izvora;
- da sam odgovarajuće naznačio/la svaku pomoć koju sam dobio/la pored pomoći mentora/ice i akademskih tutora/ica.

Sadržaj

Popis slika	5
1 Uvod	7
2 Opis problema	8
2.1 Pozadina problema	8
2.2 Matematički opis problema	8
3 Opis algoritma	15
3.1 Veza sa sistemima linearnih jednačina	15
3.1.1 Algoritam za rješavanje kvadratnog sistema linearnih jednačina	16
4 Numerički primjer	18
4.1 Numerički primjer rada algoritma	18
5 Zaključak	25
Prilozi	26
A Implementacija algoritma	27
Literatura	30

Popis slika

4.1	Grafički prikaz veza u sistemu jednačina numeričkog primjera	20
4.2	Grafički prikaz veza u sistemu nakon razdvajanja na faktor čvorove i čvorove varijabli	20

Sažetak

Ovaj rad objašnjava Gaussian Belief Propagation algoritam, bez ulaženja u diskusiju o konvergenciji algoritma, što predstavlja mnogo kompleksniji problem. Uvod ovog rada objašnjava motivaciju iza opisivanja problema procjene stanja sistema, te razliku između distribuiranih i centraliziranih algoritama.

U drugom poglavlju ovog rada je opisana detaljna matematička pozadina problema. Prvenstveno je definiran Belief Propagation algoritam i onda je na tu osnovu proširena diskusija i objašnjenje matematičke pozadine Gaussian Belief Propagation algoritma.

Treće poglavlje objašnjava da je moguće ekvivalentirati Gaussian Belief Propagation algoritam sa rješavanjem sistema linearnih jednačina i pod kojim uslovima. Objašnjene su formule koje se koriste u ovako ekvivalentiranom algoritmu, te detaljan opis postupka primjene algoritma da bi se mogao primijeniti i napisati u željenom programskom jeziku.

U četvrtom poglavlju je prikazan numerički primjer za Gaussian Belief Propagation algoritam. Opisane su detaljno vrijednosti svih značajnih varijabli u svakoj iteraciji, dok algoritam ne konvergira. Na kraju je dokazano da dobiveni vektor predstavlja egzaktno rješenje problema, čime je pokazano da, ukoliko Gaussian Belief Propagation algoritam konvergira, algoritam daje tačne rezultate. To daje veliki značaj u praktičnoj primjeni ovog algoritma. Na kraju je pokazan primjer koda implementiranog algoritma u MATLAB programskom okruženju na osnovu opisa algoritma iz trećeg poglavlja.

Unutar sistema čest je zadatak vršiti procjenu stanja sistema. Poseban problem predstavljaju sistemi kod kojih je potrebno vršiti zaključivanje te obradu stanja sistema na osnovu mjerenja više čvorova unutar distribuirane mreže sistema. Javljaju se dva oblika rješenja za takve sisteme: centralizirani i distribuirani algoritmi za estimaciju stanja.

Iako centralizirani algoritmi imaju svoje prednosti u mrežama male veličine, distribuirani sistemi su se pokazali kao efektivniji kada se mreža sastoji iz velikog broja čvorova. U ovom radu će biti predstavljene osnove Gaussian Belief Propagation¹ algoritma. Veliki dio GaBP algoritma je određivanje konvergencije datog problema, ali ovaj rad se neće baviti problemom konvergencije, samo će se u nastavku istaći neke karakteristike konvergencije ovog algoritma.

Dokazano je da ukoliko je primarna matrica sistema pozitivno semidefinitna, onda GaBP algoritam konvergira duplo eksponencijalnom² brzinom. Pored toga je dokazano da ukoliko je struktura mreže graf koji predstavlja uniju jedne petlje i stabla, onda GaBP algoritam uvijek konvergira. [1] Pokazano je empirijski da GaBP algoritam konvergira mnogo brže nego druge klasične iterativne metode. [2]

U narednom poglavlju je predstavljena matematička formulacija GaBP algoritma.

¹U nastavku teksta Gaussian Belief Propagation algoritam se označava kao GaBP algoritam

²Duplo eksponencijalna funkcija je funkcija kod koje je stepen baze eksponencijalna funkcija, dakle: a^{b^x}

2.1 Pozadina problema

Belief propagation¹ algoritam opisuje način propagacije uticaja novih dokaza i vjerovanja kroz kompleksnu mrežu hijerarhijski organiziranih inferencijskih pravila. [3] U suštini, BP je algoritam za prenošenje poruka koji računa marginalnu gustinu vjerovatnoće za svaki neopservirani čvor unutar mreže, u zavisnosti od bilo kojih opserviranih čvorova. To znači da svaki čvor unutar svake iteracije algoritma ažurira svoje mišljenje u zavisnosti od informacija koje dobija od drugih čvorova.

Statistička inferencija je proces korištenja analize podataka da bi se zaključila svojstva temeljne distribucije vjerovatnoće. [4]

GaBP algoritam je varijanta BP algoritma kada su marginalne funkcije gustine vjerovatnoće normalizirane tj. Gausove.

2.2 Matematički opis problema

U nastavku je opisan GaBP na način na koji je to urađeno u [1].

Neka postoji povezana mreža² sa M čvorova, gdje $\mathcal{V} = \{1, \dots, M\}$ predstavlja set čvorova, i $\mathcal{E}_{Net} \subset \mathcal{V} \times \mathcal{V}$ set svih neusmjerenih komunikacijskih veza u mreži, tj. ako i i j mogu komunicirati ili razmjenjivati informacije direktno, onda vrijedi: $(i, j) \in \mathcal{E}_{Net}$.

Na svakom čvoru $n \in \mathcal{V}$, lokalne opservacije su date preko linearnog Gausovog modela:

$$\mathbf{y}_n = \sum_{i \in n \cup \mathcal{I}(n)} \mathbf{A}_{n,i} \mathbf{x}_i + \mathbf{z}_n \quad (2.1)$$

gdje $\mathcal{I}(n)$ predstavlja set susjeda čvora n tj. sve čvorove i gdje $(n, i) \in \mathcal{E}_{Net}$, $\mathbf{A}_{n,i}$ je poznata matrica koeficijenata sa punim rangom kolona, $\mathbf{x}_i$ je lokalna nepoznata na čvoru i sa dimenzijom $N_i \times 1$ i sa funkcijom gustine vjerovatnoće $x_i \sim \mathcal{N}(\mathbf{x}_i | \mathbf{0}, \mathbf{W}_i)(\mathbf{W}_i \succ \mathbf{0})$ i $\mathbf{z}_n$ je aditivni šum sa funkcijom gustine vjerovatnoće

¹U nastavku teksta Belief Propagation algoritam se označava kao BP algoritam

²Povezana mreža je ona mreža gdje bilo koja dva čvora unutar mreže mogu komunicirati jedan sa drugim kroz konačan broj skokova.

$$\mathbf{z}_n \sim \mathcal{N}(\mathbf{z}_n | \mathbf{0}, \mathbf{R}_n) (\mathbf{R}_n \succ \mathbf{0})^3.$$

Pretpostavlja se da vrijedi $p(\mathbf{x}_i, \mathbf{x}_j) = p(\mathbf{x}_i)p(\mathbf{x}_j)$ ⁴ i $p(\mathbf{z}_i, \mathbf{z}_j) = p(\mathbf{z}_i)p(\mathbf{z}_j)$ za $i \neq j$, i x_i i z_j su nezavisni za sve i i j . Cilj je naći $\mathbf{x}_i$, na osnovu $\mathbf{y}_n$, $p(\mathbf{x}_i)$ i $p(\mathbf{z}_n)$.

U centraliziranoj estimaciji, sve opservacije $\mathbf{y}_n$ na različitim čvorovima se prenose na centralizovano mjesto za procesiranje podataka. Definiraju se vektori $\mathbf{x}$, $\mathbf{y}$ i $\mathbf{z}$ kao konkatencija vektora $\mathbf{x}_n$, $\mathbf{y}_n$ i $\mathbf{z}_n$ u rastućem poretku u odnosu na n , respektivno:

$$\mathbf{y} = \mathbf{A}\mathbf{x} + \mathbf{z} \quad (2.2)$$

gdje se $\mathbf{A}$ konstruisalo iz $\mathbf{A}_{n,i}$ sa specifičnim redoslijedom koji zavisi od topologije mreže.

Pod pretpostavkom da su kolone $\mathbf{A}$ linerano nezavisne, i kako je jednačina 2.2 standardni linearni model, procjena minimalne srednjekvadratne greške $\hat{\mathbf{x}} \triangleq [\hat{\mathbf{x}}_1^T, \dots, \hat{\mathbf{x}}_M^T]^T$ od $\mathbf{x}$ je:

$$\hat{\mathbf{x}} = \int \mathbf{x} \frac{p(\mathbf{x})p(\mathbf{y}|\mathbf{x})}{\int p(\mathbf{x})p(\mathbf{y}|\mathbf{x})} d\mathbf{x} = (\mathbf{W}^{-1} + \mathbf{A}^T \mathbf{R}^{-1} \mathbf{A})^{-1} \mathbf{A}^T \mathbf{R}^{-1} \mathbf{y} \quad (2.3)$$

gdje su $\mathbf{W}$ i $\mathbf{R}$ blok dijagonalne matrice koje sadrže $\mathbf{W}_i$ i $\mathbf{R}_i$ kao svoje dijagonalne blokove, respektivno.

Sa druge strane, GaBP algoritam koji se vrši preko grafičkih modela koji predstavljaju zajedničku funkciju raspodjele vjerovatnoće svih $\mathbf{x}_i$ daje distribuirani način da se nađe $\mathbf{x}_i$ lokalno, što izbjegava nedostatke centraliziranog pristupa.

Konkretno, za Gausov MRF⁵, zajednička funkcija vjerovatnoće $p(\mathbf{x})p(\mathbf{y}|\mathbf{x})$ se izražava u parovima:

$$p(\mathbf{x})p(\mathbf{y}|\mathbf{x}) = \prod_{n \in \mathcal{V}} \psi_n(\mathbf{x}_n, \{\mathbf{y}_i\}_{i \in \{n \cup \mathcal{I}(n)\}}) \prod_{(n,i) \in \mathcal{E}_{MRF}} \psi_{n,i}(\mathbf{x}_n, \mathbf{x}_i) \quad (2.4)$$

gdje je

$$\mathcal{E}_{MRF} \triangleq \mathcal{E}_{Net} \cup \{(n,i) | \exists k, k \neq n, k \neq i : (n,k) \in \mathcal{E}_{Net} \wedge (i,k) \in \mathcal{E}_{Net}\} \quad (2.5)$$

³Za Hermitijanske matrice, dakle kompleksne kvadratne matrice koje su jednake svojem konjugovano kompleksnom transponiranom obliku ($\mathbf{A}$ je Hermitijanska matrica $\iff \mathbf{A} = \overline{\mathbf{A}^T}$), $\mathbf{X}$ i $\mathbf{Y}$, $\mathbf{X} \succeq \mathbf{Y}$ ($\mathbf{X} \succ \mathbf{Y}$) znači da je $\mathbf{X} - \mathbf{Y}$ pozitivno semidefinitno (definitno).

⁴U nastavku rada funkcija $p(\mathbf{x})$ označava funkciju vjerovatnoće.

⁵Gaussian Markov random field je specijalni tip slučajnog polja koji ima Markov svojstva.

$$\psi_n(\mathbf{x}_n, \{\mathbf{y}_i\}_{i \in n \cup \mathcal{I}(n)}) = \exp \left\{ \frac{1}{2} \left(\mathbf{x}_n^T \mathbf{W}_n^{-1} \mathbf{x}_n + \sum_{i \in n \cup \mathcal{I}(n)} \mathbf{y}_i^T \mathbf{R}_i^{-1} \mathbf{x}_n \right) \right\} \quad (2.6)$$

Jednačina 2.6 predstavlja potencijalnu funkciju na čvoru n , dok je jednačina 2.7 rubni potencijal između $\mathbf{x}_n$ i $\mathbf{x}_i$. Nakon što se postavi grafički model koji predstavlja zajedničku funkciju vjerovatnoće u 2.4, poruke se razmjenjuju između parova čvorova n i i gdje vrijedi $(n, i) \in \mathcal{E}_{MRF}$.

$$\begin{aligned} \psi_{n,i}(\mathbf{x}_n, \mathbf{x}_i) = \exp - \left\{ \frac{1}{2} \left[(\mathbf{A}_{n,n} \mathbf{x}_n)^T \mathbf{R}_n^{-1} (\mathbf{A}_{n,n} \mathbf{x}_n) + (\mathbf{A}_{i,n} \mathbf{x}_n)^T \mathbf{R}_i^{-1} (\mathbf{A}_{i,n} \mathbf{x}_n) \right. \right. \\ \left. \left. + \sum_{k \in \{\tilde{k} | (\tilde{k}, i) \in \mathcal{E}_{Net}, (\tilde{k}, n) \in \mathcal{E}_{Net}\}} (\mathbf{A}_{k,n} \mathbf{x}_n)^T \mathbf{R}_k^{-1} (\mathbf{A}_{k,n} \mathbf{x}_n) \right] \right\} \quad (2.7) \end{aligned}$$

Specifično, prema standardnoj derivaciji GaBP-a, u iteraciji l , poruka koja se šalje od čvora n do čvora i je:

$$w_{n \rightarrow i}^{(l)}(\mathbf{x}_i) = \int \psi_n(\mathbf{x}_n, \{\mathbf{y}_k\}_{k \in n \cup \mathcal{I}(n)}) \psi_{n,i}(\mathbf{x}_n, \mathbf{x}_i) \prod_{k \in \mathcal{I}(n) \setminus i} w_{k \rightarrow n}^{(l-1)}(\mathbf{x}_n) d\mathbf{x}_n \quad (2.8)$$

Kako je pokazano u 2.8, GaBP je iterativan, gdje svaki čvor alternirajući prima poruke od svojih susjeda i šalje dalje ažurirane poruke. U svakoj iteraciji, čvor i računa svoje vjerovanje (engl. *belief*) o varijabli $\mathbf{x}_i$, kao:

$$b_{MRF}^{(l)}(\mathbf{x}_i) \propto \psi_i(\mathbf{x}_i, \{\mathbf{y}_n\}_{n \in i \cup \mathcal{I}(i)}) \prod_{k \in \mathcal{I}(n)} w_{k \rightarrow i}^{(l)}(\mathbf{x}_i) \quad (2.9)$$

Prema [5], ukoliko 2.8 konvergira, onda srednja vrijednost vjerovanja 2.9 je tačna srednja vrijednost marginalne funkcije gustine vjerovatnoće od $\mathbf{x}_i$.

Pošto postoje ograničenja za navedeni Gaussian MRF pristup, dalje u tekstu je izveden distribuirana vektorska inferencija koja se bazira na GaBP algoritmu sa interakcijama višeg reda (ne samo u parovima), gdje uslov za dijeljenje informacija i razmjenjivanje poruka podliježe fizičkoj topologiji mreže, onako kako je opisano u [1].

Zajednička funkcija vjerovatnoće se prvo piše kao proizvod prethodne vjerovatnoće i vjerovatnoće svakog lokalnog linearnog Gausovog modela u 2.1 kao:

$$p(\mathbf{x})p(\mathbf{y}|\mathbf{x}) = \prod_{n \in \mathcal{V}} p(\mathbf{x}_n) \prod_{n \in \mathcal{V}} \underbrace{p(\mathbf{y}_n | \{\mathbf{x}_i\}_{i \in n \cup \mathcal{I}(n)})}_{\triangleq f_n} \quad (2.10)$$

Kako bi se omogućilo deriviranje distribuiranog algoritma inferencije, 2.10 se izražava kao faktor graf gdje se svaka vektor varijabla $\mathbf{x}_i$ predstavlja kao krug (koji se zove čvor promjenljive) i raspodjela vjerovatnoće vektor varijable ili grupe vektor varijabli se predstavlja kao kvadrat (koji se zove faktor čvor).

Čvor promjenljive je povezan sa faktor čvorom ako je varijabla uključena u taj specifični faktor. Slikoviti prikaz ovog opisa je pokazan na slici 4.2, u poglavlju koje opisuje numerički primjer rješavanja sistema primjenjujući GaBP algoritam.

Deriviramo GaBP algoritam preko odgovarajućeg faktor grafa kako bi smo odredili $\mathbf{x}_n$ za svako $n \in \mathcal{V}$. Postoje dva tipa poruka: poruka od čvora promjenljive $\mathbf{x}_j$ do svog susjednog faktor čvor f_n , koja se definira kao:

$$m_{j \rightarrow f_n}^{(l)}(\mathbf{x}_j) = p(\mathbf{x}_j) \prod_{f_k \in \mathcal{B}(j) \setminus f_n} m_{f_k \rightarrow j}^{(l-1)}(\mathbf{x}_j) \quad (2.11)$$

gdje $\mathcal{B}(j)$ označava set susjednih faktor čvorova od $\mathbf{x}_j$, i $m_{f_k \rightarrow j}^{(l-1)}(\mathbf{x}_j)$ je poruka od f_k ka $\mathbf{x}_j$ u vremenu $l-1$. Drugi tip poruke je od faktor čvora f_n ka susjednom čvoru promjenljive $\mathbf{x}_i$, koja se definira kao:

$$m_{f_n \rightarrow i}^{(l)}(\mathbf{x}_i) = \int \cdots \int f_n \times \prod_{j \in \mathcal{B}(f_n) \setminus i} m_{j \rightarrow f_n}^{(l)}(\mathbf{x}_j) d\{\mathbf{x}_j\}_{j \in \mathcal{B}(f_n) \setminus i} \quad (2.12)$$

gdje $\mathcal{B}(f_n)$ označava set susjednih čvorova promjenljive od f_n . Proces onda se iterativno izvršava između 2.11 i 2.12. U svakoj iteraciji l , aproksimirana približna vrijednost marginalne funkcije gustine vjerovatnoće koja se referira kao vjerovanje, od $\mathbf{x}_i$ se računa lokalno na $\mathbf{x}_i$ kao:

$$b_{BP}^{(l)}(\mathbf{x}_i) = p(\mathbf{x}_i) \prod_{f_n \in \mathcal{B}(i)} m_{f_n \rightarrow i}^{(l)}(\mathbf{x}_i) \quad (2.13)$$

U nastavku teksta su dati tačni izrazi za poruke $m_{j \rightarrow f_n}^{(l)}(\mathbf{x}_j)$, $m_{f_n \rightarrow i}^{(l)}(\mathbf{x}_i)$ i vjerovanje $b_{BP}^{(l)}(\mathbf{x}_i)$. Inicijalne poruke na svakom čvoru promjenljive i faktor čvoru u Gausovoj funkcionalnoj formi se izražavaju kao:

$$m_{f_n \rightarrow i}^{(0)}(\mathbf{x}_i) \propto \exp \left\{ -\frac{1}{2} \|\mathbf{x}_i - \mathbf{v}_{f_n \rightarrow i}^{(0)}\|_{\mathbf{J}_{f_n \rightarrow i}^{(0)}}^2 \right\} \quad (2.14)$$

Generalni izraz za poruku od čvora promjenljive j do faktor čvor f_n je:

$$m_{f_n \rightarrow i}^{(l)}(\mathbf{x}_i) \propto \exp \left\{ -\frac{1}{2} \|\mathbf{x}_i - \mathbf{v}_{f_n \rightarrow i}^{(l)}\|_{\mathbf{J}_{f_n \rightarrow i}^{(l)}}^2 \right\} \quad (2.15)$$

gdje vrijedi da su:

$$\mathbf{J}_{j \rightarrow f_n}^{(l)} = \mathbf{W}_j^{-1} + \sum_{f_k \in \mathcal{B}(j) \setminus f_n} \mathbf{J}_{f_k \rightarrow j}^{(l-1)} \quad (2.16)$$

$$\mathbf{v}_{j \rightarrow f_n}^{(l)} = \left[\mathbf{J}_{j \rightarrow f_n}^{(l)} \right]^{-1} \left[\sum_{f_k \in \mathcal{B}(j) \setminus f_n} \mathbf{J}_{f_k \rightarrow j}^{(l-1)} \mathbf{v}_{f_k \rightarrow j}^{(l-1)} \right] \quad (2.17)$$

gdje su $\mathbf{J}_{j \rightarrow f_n}^{(l)}$ i $\mathbf{v}_{j \rightarrow f_n}^{(l)}$ matrice informacije poruka (inverzne od matrice kovarijansi) i vektor srednjih vrijednosti koji se prima na čvoru promjenljive j u $(l-1)$. iteraciji, respektivno. Dalje, poruka od faktor čvora f_n ka čvoru promjenljive i je data kao:

$$m_{f_n \rightarrow i}^{(l)}(\mathbf{x}_i) \propto \alpha_{f_n \rightarrow i}^{(l)} \exp \left\{ -\frac{1}{2} \|\mathbf{x}_i - \mathbf{v}_{f_n \rightarrow i}^{(l)}\|_{\mathbf{J}_{f_n \rightarrow i}^{(l)}}^2 \right\} \quad (2.18)$$

gdje su:

$$\mathbf{J}_{f_n \rightarrow i}^{(l)} = \mathbf{A}_{n,i}^T \left[\mathbf{R}_n + \sum_{j \in \mathcal{B}(f_n) \setminus i} \mathbf{A}_{n,j} \left[\mathbf{J}_{j \rightarrow f_n}^{(l)} \right]^{-1} \mathbf{A}_{n,j}^T \right]^{-1} \mathbf{A}_{n,i} \quad (2.19)$$

$$\mathbf{v}_{f_n \rightarrow i}^{(l)} = \left[\mathbf{J}_{f_n \rightarrow i}^{(l)} \right]^{-1} \mathbf{A}_{n,i}^T \left[\mathbf{R}_n + \sum_{j \in \mathcal{B}(f_n) \setminus i} \mathbf{A}_{n,j} \left[\mathbf{J}_{j \rightarrow f_n}^{(l)} \right]^{-1} \mathbf{A}_{n,j}^T \right]^{-1} \mathbf{A}_{n,i} \quad (2.20)$$

$$\begin{aligned} \mathbf{v}_{f_n \rightarrow i}^{(l)} = & \left[\mathbf{J}_{f_n \rightarrow i}^{(l)} \right]^{-1} \mathbf{A}_{n,i}^T \left[\mathbf{R}_n + \sum_{j \in \mathcal{B}(f_n) \setminus i} \mathbf{A}_{n,j} \left[\mathbf{J}_{j \rightarrow f_n}^{(l)} \right]^{-1} \mathbf{A}_{n,j}^T \right]^{-1} \cdot \\ & \cdot \left(\mathbf{y}_n - \sum_{j \in \mathcal{B}(f_n) \setminus i} \mathbf{A}_{n,j} \mathbf{v}_{j \rightarrow f_n}^{(l)} \right) \end{aligned} \quad (2.21)$$

$$\alpha_{f_n \rightarrow i}^{(l)} \propto \int \cdots \int \exp \left\{ -\frac{1}{2} \mathbf{z}^T \mathbf{\Lambda}_{f_n \rightarrow i}^{(l)} \mathbf{z} \right\} d\mathbf{z} \quad (2.22)$$

U 2.22, $\mathbf{\Lambda}_{f_n \rightarrow i}^{(l)}$ je dijagonalna matrica koja sadrži svojstvene vrijednosti od $\mathbf{A}_{n, \{\mathcal{B}(f_n) \setminus i\}}^T \mathbf{R}_n^{-1} \mathbf{A}_{n, \{\mathcal{B}(f_n) \setminus i\}} + \mathbf{J}_{\{\mathcal{B}(f_n) \setminus i\} \rightarrow f_n}^{(l)}$, gdje je $\mathbf{A}_{n, \{\mathcal{B}(f_n) \setminus i\}}$ redna blokovna matrica koja sadrži $\mathbf{A}_{n,j}$ kao elemente redova za svako $j \in \mathcal{B}(f_n) \setminus i$ organiziranih u rastućem poretku, i $\mathbf{J}_{\{\mathcal{B}(f_n) \setminus i\} \rightarrow f_n}^{(l)}$ je blok dijagonalna matrica sa $\mathbf{J}_{j \rightarrow f_n}^{(l)}$ kao elemente u blok dijagonali za svako $j \in \mathcal{B}(f_n) \setminus i$ poredanih u rastućem poretku.

Potreban i dovoljan uslov za egzistenciju $m_{f_n \rightarrow i}^{(l)}(\mathbf{x}_i)$ je:

$$\mathbf{A}_{n, \{\mathcal{B}(f_n) \setminus i\}}^T \mathbf{R}_n^{-1} \mathbf{A}_{n, \{\mathcal{B}(f_n) \setminus i\}} + \mathbf{J}_{\{\mathcal{B}(f_n) \setminus i\} \rightarrow f_n}^{(l)} \succ \mathbf{0} \quad (2.23)$$

Inače, potreban i dovoljan uslov je teško potvrditi, zbog toga što se $\mathbf{J}_{\{\mathcal{B}(f_n) \setminus i\} \rightarrow f_n}^{(l)}$ mijenja u svakoj iteraciji. Međutim, kako $\mathbf{R}_n^{-1} \succ \mathbf{0}$, onda se može napisati kao $\mathbf{R}_n^{-1} = \tilde{\mathbf{R}}_n^T \tilde{\mathbf{R}}_n$, pa vrijedi:

$$\mathbf{A}_{n, \{\mathcal{B}(f_n) \setminus i\}}^T \mathbf{R}_n^{-1} \mathbf{A}_{n, \{\mathcal{B}(f_n) \setminus i\}} = \left(\tilde{\mathbf{R}}_n \mathbf{A}_{n, \{\mathcal{B}(f_n) \setminus i\}} \right)^T \left(\tilde{\mathbf{R}}_n \mathbf{A}_{n, \{\mathcal{B}(f_n) \setminus i\}} \right) \succeq \mathbf{0} \quad (2.24)$$

Dakle, jedan jednostavan dovoljan uslov da garantira 2.22 je $\mathbf{J}_{\{\mathcal{B}(f_n) \setminus i\} \rightarrow f_n}^{(l)} \succ \mathbf{0}$ ili ekvivalentno njena dijagonalna blok matrica $\mathbf{J}_{j \rightarrow f_n}^{(l)} \succ \mathbf{0}$ za svako $j \in \mathcal{B}(f_n) \setminus i$.

Konačno, ako GaBP poruke postoje, prema definiciji vjerovanja u 2.13, $\mathbf{b}_{BP}^{(l)}(\mathbf{x}_i)$ u iteraciji (l) se računa kao:

$$\mathbf{b}_{BP}^{(l)}(\mathbf{x}_i) = p(\mathbf{x}_i) \prod_{f_n \in \mathcal{B}(i)} m_{f_n \rightarrow i}^{(l)}(\mathbf{x}_i) \propto \mathcal{N} \left(\mathbf{x}_i | \mu_i^{(l)}, \mathbf{P}_i^{(l)} \right) \quad (2.25)$$

gdje je matrica kovarijanse vjerovanja:

$$\mathbf{P}_i^{(l)} = \left[\mathbf{W}_i^{-1} + \sum_{f_n \in \mathcal{B}(i)} \mathbf{J}_{f_n \rightarrow i}^{(l)} \right]^{-1} \quad (2.26)$$

i vektor srednjih vrijednosti je:

$$\mu_i^{(l)} = \mathbf{P}_i^{(l)} \left[\sum_{f_n \in \mathcal{B}(i)} \mathbf{J}_{f_n \rightarrow i}^{(l)} \mathbf{v}_{f_n \rightarrow i}^{(l)} \right] \quad (2.27)$$

U poglavlju 3 je objašnjen algoritam koji se zasniva na GaBP, gdje je uzeto da je vektor $\mathbf{z}$ iz 2.2 jednak nuli (dakle, posmatran je sistem koji nema šuma). Konkretno, pokazat će se da postoji veza statističke inferencije sa problemom rješavanja kvadratnog sistema linearnih jednačina.

3.1 Veza sa sistemima linearnih jednačina

Do sada se posmatrao problem statističke inferencije za određivanje temeljne multi-varijabilne funkcije gustine vjerovatnoće. GaBP problem se može ekvivalentirati sa rješavanjem sistema linearnih jednačina $\mathbf{Ax} = \mathbf{b}$, pod uslovom da je $\mathbf{A}$ simetrična pozitivno-definitna matrica. Rješenje $\mathbf{x}$ će se dobiti kao vektor srednjih vrijednosti raspodjele u GaBP ekvivalentu.

Kao što je prikazano u [6], a što se direktno može dobiti iz opisa problema u ovom radu, Gaussian belief propagation rješava problem maksimizacije naredne funkcije:

$$\exp\left(-\frac{1}{2}\mathbf{x}^T\mathbf{Ax} + \mathbf{b}^T x\right) \quad (3.1)$$

u odnosu na $\mathbf{x}$. Maksimizacija ove eksponencijalne funkcije se dobija maksimizacijom njenog eksponenta, odnosno maksimizacijom idućeg:

$$-\frac{1}{2}\mathbf{x}^T\mathbf{Ax} + \mathbf{b}^T x \quad (3.2)$$

u odnosu na $\mathbf{x}$. Jednostavnim množenjem sa -1 problem se svodi na problem minimizacije vrijednosti:

$$\frac{1}{2}\mathbf{x}^T\mathbf{Ax} - \mathbf{b}^T x \quad (3.3)$$

u odnosu na $\mathbf{x}$. Kako je ovo kvadratna funkcija u odnosu na $\mathbf{x}$, te $\mathbf{A}$ je simetrična pozitivno-definitna matrica tako se maksimum funkcije dostiže u tački gdje je njen izvod u odnosu na $\mathbf{x}$ jednak $\mathbf{0}$, odnosno problem se svodi na rješavanje jednačine:

$$\mathbf{Ax} - \mathbf{b} = \mathbf{0} \quad (3.4)$$

u odnosu na $\mathbf{x}$. Ovo je ekvivalentno klasičnom problemu rješavanja sistema linearnih jednačina, odnosno potrebno je naći $\mathbf{x}$ kako bi vrijedilo sljedeće:

$$\mathbf{Ax} = \mathbf{b} \quad (3.5)$$

Dakle, rješavanje problema statističke inferencije GaBP problema je ekvivalentno rješavanju sistema linearnih jednačina. U skladu sa promjenom perspektive objasniti će se algoritam kojim se postupkom rješavanja GaBP problema rješava sistem linearnih jednačina.

3.1.1 Algoritam za rješavanje kvadratnog sistema linearnih jednačina

Kako se algoritam posmatra iz druge perspektive neće se prikazati matematičko izvođenje novog problema. Cilj je ponuditi čitaocu nacrt algoritma kako bi se isti mogao replicirati. Ovaj algoritam je zasnovan na isječku iz [7], a rješava problem rješavanja jednačine 3.5 u odnosu na vektor $\mathbf{x}$.

Prije svega, generiše se neusmjereni graf sa N čvorova, označeni brojevima od 1 do N , gdje je N broj jednačina (a samim tim i nepoznatih) u linearnom sistemu. Dva čvora i i j u ovom grafu su povezani ako i samo ako $\mathbf{A}_{ij} \neq 0$, gdje $\mathbf{A}_{ij}$ predstavlja element reda i i kolone j matrice $\mathbf{A}$.

Susjedstvo čvora i je označeno sa $S(i)$. Svaki čvor će komunicirati samo sa svojim susjedima. Za generisanje poruke koristit će informacije o porukama koje je primio od susjeda iz prethodne iteracije, kao i informacije o matrici $\mathbf{A}$.

Svaki čvor i svom susjedu j šalje dvije vrste poruka. Prva vrsta poruka su poruke P_{ij} , koje su ekvivalenti porukama od faktor čvora agenta i do čvora promjenljive agenta j . Druga vrsta poruka su poruke μ_{ij} , koje su ekvivalenti porukama od čvora promjenljive agenta i do faktor čvora agenta j .

Također, inicijalno vjerovanje čvora i o samom sebi je predstavljen vrijednostima P_{ii} i μ_{ii} . Ove vrijednosti se ne mijenjaju kroz iteracije algoritma i jednostavno se određuju preko sljedećih izraza:

$$P_{ii} = A_{ii} \quad (3.6)$$

i

$$\mu_{ii} = \frac{b_i}{A_{ii}} \quad (3.7)$$

U prvoj iteraciji poruke su nulte, u narednim iteracijama poruke se zasnivaju na primljenim porukama iz prethodne iteracije. Poruke koje je čvor i poslao čvoru j u prethodnoj iteraciji se označavaju sa $\bar{P}_{ij}$ i $\bar{\mu}_{ij}$.

Skup svih susjeda čvora i izuzev čvora j , u skladu sa standardnim matematičkim oznakama, se označava sa $S(i) \setminus j$. Sada se mogu definirati formule kojima se određuju poruke koje se generišu i šalju od čvora i svom susjedu, čvoru j . To su:

$$P_{ij} = -A_{ij}^2 \left(P_{ii} + \sum_{k \in S(i) \setminus j} \overline{P_{ki}} \right)^{-1} \quad (3.8)$$

i

$$\mu_{ij} = A_{ij}^{-1} \left(P_{ii} \mu_{ii} + \sum_{k \in S(i) \setminus j} \overline{P_{ki}} \overline{\mu_{ki}} \right) \quad (3.9)$$

Vrijedno spomena je da su vrijednosti koje se invertuju skalari, te da su A_{ij} i P_{ii} uvijek nenulte vrijednosti u ovim formulama.

Također, ključna je informacija da se ovaj postupak može distribuirano obavljati, odnosno svaki čvor svoju iduću poruku može nezavisno računati. Ukoliko je graf stablo i vrijede osnovne pretpostavke kao da su rješenja postoje i konačna su, te da je matrica $\mathbf{A}$ simetrična i pozitivno-definitna, onda je za konvergenciju dovoljno obaviti broj iteracija koji za jedan veći od prečnika stabla generisanog grafa.

U teoriji grafova prečnik stabla je minimalna udaljenost između dvije najudaljenije tačke grafa. Ovo znači da je uvijek dovoljno obaviti N iteracija, neovisno od strukture stabla. Konvergencija u drugim slučajevima je detaljnije analizirana u [1].

To vrijedi za sinhronizovano slanje poruka. Velika prednost ovog algoritma je što i čvorovi ne moraju biti usklađeni po pitanju slanja poruka, te da će algoritam i u tom slučaju konvergirati, ali broj potrebnih iteracija blisko ovisi o redoslijedu slanja poruka.

Za kriterij zaustavljanja algoritma može se uzeti maksimalni broj iteracija N , kao i minimalnu potrebnu promjenu vrijednosti P_{ij} i μ_{ij} za nastavak rada. Predlažemo izbor varijable minimalne promjene ϵ kao minimalne vrijednosti za zbir kvadrata promjena svih vrijednosti P_{ij} i μ_{ij} takvih da vrijedi $j \in S(i)$ (čime vrijedi i $i \in S(j)$), te $i \neq j$.

Nakon konvergencije i zaustavljanja algoritma, mogu se izračunati marginalne srednje vrijednosti i marginalne preciznosti, no kako je samo potrebno naći rješenje sistema jednačina, u nastavku je prikazano kako se traženo rješenje određuje.

Rješenje sistema je $\mathbf{x} = [x_1 \ x_2 \ x_3 \ \dots \ x_N]^T$, gdje x_i za sve $i \in \{1, 2, 3, \dots, N\}$ se računa preko sljedećeg izraza:

$$x_i = \left(P_{ii} \mu_{ii} + \sum_{k \in S(i)} P_{ki} \mu_{ki} \right) \left(P_{ii} + \sum_{k \in S(i)} P_{ki} \right)^{-1} \quad (3.10)$$

Ovim je okončan algoritam i nađeno je rješenje $\mathbf{x}$ sistema $\mathbf{Ax} = \mathbf{b}$.

4.1 Numerički primjer rada algoritma

Prikažimo rad algoritma na numeričkom primjeru. Potrebno je riješiti sljedeći sistem jednačina:

$$5x_1 + 2x_2 = 3 \quad (4.1)$$

$$2x_1 + 2x_2 + 3x_3 = 1.5 \quad (4.2)$$

$$3x_2 + 10x_3 + x_4 - x_5 = 2 \quad (4.3)$$

$$x_3 + 2x_4 = 4.5 \quad (4.4)$$

$$-x_3 + 2x_5 = 3.5 \quad (4.5)$$

Pretvaranjem ovog problema u matrični oblik dobijamo:

$$\begin{pmatrix} 5 & 2 & 0 & 0 & 0 \\ 2 & 2 & 3 & 0 & 0 \\ 0 & 3 & 10 & 1 & -1 \\ 0 & 0 & 1 & 2 & 0 \\ 0 & 0 & -1 & 0 & 2 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \\ x_5 \end{pmatrix} = \begin{pmatrix} 3 \\ 1.5 \\ 2 \\ 4.5 \\ 3.5 \end{pmatrix} \quad (4.6)$$

Ovim smo pretvorili sistem u oblik $\mathbf{Ax} = \mathbf{b}$, gdje vrijedi:

$$\mathbf{A} = \begin{pmatrix} 5 & 2 & 0 & 0 & 0 \\ 2 & 2 & 3 & 0 & 0 \\ 0 & 3 & 10 & 1 & -1 \\ 0 & 0 & 1 & 2 & 0 \\ 0 & 0 & -1 & 0 & 2 \end{pmatrix} \quad (4.7)$$

$$\mathbf{b} = \begin{pmatrix} 3 \\ 1.5 \\ 2 \\ 4.5 \\ 3.5 \end{pmatrix} \quad (4.8)$$

Možemo primjetiti da je matrica $\mathbf{A}$ simetrična i možemo provjeriti da je i pozitivno definitna, tako da lagano možemo zaključiti da će GaBP algoritam konvergirati brzo.

Dalje, generišemo graf od 5 čvorova, spajajući čvorove na osnovu pozicija nenulatih elemenata matrice $\mathbf{A}$. Ovim dobijamo graf prikazan na slici 4.1. Na slici 4.2 je prikazan graf veza u sistemu nakon razdvajanja čvorova na faktor čvorove i čvorove varijabli, onako kako je opisano u poglavlju 2.

Na osnovu acikličnosti grafa, simetričnosti i pozitivno definitne prirode matrice $\mathbf{A}$ možemo zaključiti da je maksimalni broj iteracija algoritma prije konvergencije 4, odnosno to je jednako prečniku stabla plus jedan.

U skladu sa opisom algoritma prvo ćemo računati vrijednosti P_{ii} i μ_{ii} koje se ne mijenjaju u toku rada algoritma. Ove vrijednosti su:

$$P_{11} = A_{11} = 5$$

$$P_{22} = A_{22} = 2$$

$$P_{33} = A_{33} = 10$$

$$P_{44} = A_{44} = 2$$

$$P_{55} = A_{55} = 2$$


$$\mu_{11} = b_1/A_{11} = 0.6$$

$$\mu_{22} = b_2/A_{22} = 0.75$$


$$\mu_{33} = b_3/A_{33} = 0.2$$

$$\mu_{44} = b_4/A_{44} = 2.25$$

$$\mu_{55} = b_5/A_{55} = 1.75$$



Slika 4.1: Grafički prikaz veza u sistemu jednačina numeričkog primjera



Slika 4.2: Grafički prikaz veza u sistemu nakon razdvajanja na faktor čvorove i čvorove varijabli

Početne vrijednosti poruka koje se odašilju su 0, a to su:

$$\begin{aligned}
 P_{12} &= 0 \\
 P_{21} &= P_{23} = 0 \\
 P_{32} &= P_{34} = P_{35} = 0 \\
 P_{43} &= 0 \\
 P_{53} &= 0
 \end{aligned}$$

$$\begin{aligned}
\mu_{12} &= 0 \\
\mu_{21} &= \mu_{23} = 0 \\
\mu_{32} &= \mu_{34} = \mu_{35} = 0 \\
\mu_{43} &= 0 \\
\mu_{53} &= 0
\end{aligned}$$

Ove poruke se šalju čime se završava prva iteracija algoritma. Ove poruke postaju poruke prethodne iteracije $\bar{P}_{ij}$ i $\bar{\mu}_{ij}$. Poruke iduće iteracije se računaju:

$$\begin{aligned}
P_{12} &= -A_{12}^2/(P_{11}) = -4/5 = -0.8 \\
P_{21} &= -A_{21}^2/(P_{22} + \bar{P}_{32}) = -4/2 = -2 \\
P_{23} &= -A_{23}^2/(P_{22} + \bar{P}_{12}) = -9/2 = -4.5 \\
P_{32} &= -A_{32}^2/(P_{33} + \bar{P}_{43} + \bar{P}_{53}) = -9/10 = -0.9 \\
P_{34} &= -A_{34}^2/(P_{33} + \bar{P}_{23} + \bar{P}_{53}) = -1/10 = -0.1 \\
P_{35} &= -A_{35}^2/(P_{33} + \bar{P}_{23} + \bar{P}_{43}) = -1/10 = -0.1 \\
P_{43} &= -A_{43}^2/(P_{44}) = -1/2 = -0.5 \\
P_{53} &= -A_{53}^2/(P_{55}) = -1/2 = -0.5 \\
\\
\mu_{12} &= (P_{11}\mu_{11})/A_{12} = 3/2 = 1.5 \\
\mu_{21} &= (P_{22}\mu_{22} + \bar{P}_{32}\bar{\mu}_{32})/A_{21} = 1.5/2 = 0.75 \\
\mu_{23} &= (P_{22}\mu_{22} + \bar{P}_{12}\bar{\mu}_{12})/A_{23} = 1.5/3 = 0.5 \\
\mu_{32} &= (P_{33}\mu_{33} + \bar{P}_{43}\bar{\mu}_{43} + \bar{P}_{53}\bar{\mu}_{53})/A_{32} = 2/3 \approx 0.6667 \\
\mu_{34} &= (P_{33}\mu_{33} + \bar{P}_{23}\bar{\mu}_{23} + \bar{P}_{53}\bar{\mu}_{53})/A_{34} = 2/1 = 2 \\
\mu_{35} &= (P_{33}\mu_{33} + \bar{P}_{23}\bar{\mu}_{23} + \bar{P}_{43}\bar{\mu}_{43})/A_{35} = 2/(-1) = -2 \\
\mu_{43} &= (P_{44}\mu_{44})/A_{43} = 4.5/1 = 4.5 \\
\mu_{53} &= (P_{55}\mu_{55})/A_{53} = 3.5/(-1) = -3.5
\end{aligned}$$

Transmisijom ovih poruka se završava druga iteracija algoritma. Kako vidimo da nisu sve vrijednosti ostale iste tako zaključujemo da algoritam nije konvergirao, te nastavljamo sa radom. Sve primljene poruke P_{ij} i μ_{ij} iz ove iteracije postaju poruke iz prethodne iteracije $\bar{P}_{ij}$ i $\bar{\mu}_{ij}$, redom.

Formule za računanje poruka se ne mijenjaju u toku rada algoritma, tako da ih u nastavku izostavljamo, te samo pišemo izračunate vrijednosti.

$$\begin{aligned}P_{12} &= -0.8 \\P_{21} &= -4/1.1 \approx -3.6364 \\P_{23} &= -7.5 \\P_{32} &= -1 \\P_{34} &= -0.2 \\P_{35} &= -0.2 \\P_{43} &= -0.5 \\P_{53} &= -0.5\end{aligned}$$

$$\begin{aligned}\mu_{12} &= 1.5 \\ \mu_{21} &= 0.45 \\ \mu_{23} &= 0.1 \\ \mu_{32} &= 0.5 \\ \mu_{34} &= 1.5 \\ \mu_{35} &= 2.5 \\ \mu_{43} &= 4.5 \\ \mu_{53} &= -3.5\end{aligned}$$

Ponovo, transmisijom ovih poruka one postaju primljene poruke iz prethodne iteracije, te završava treća iteracija. Vidimo da su se vrijednosti poruka promijenile, tako da algoritam nije konvergirao. Poruke četvrte iteracije su prikazane ispod:

$$\begin{aligned}P_{12} &= -0.8 \\P_{21} &= -4 \\P_{23} &= -7.5 \\P_{32} &= -1 \\P_{34} &= -0.5 \\P_{35} &= -0.5 \\P_{43} &= -0.5 \\P_{53} &= -0.5\end{aligned}$$

$$\mu_{12} = 1.5$$

$$\mu_{21} = 0.5$$

$$\mu_{23} = 0.1$$

$$\mu_{32} = 0.5$$

$$\mu_{34} = 3$$

$$\mu_{35} = 1$$

$$\mu_{43} = 4.5$$

$$\mu_{53} = 3.5$$

Transmisijom ovih poruka se završava četvrta iteracija algoritma. Pošto nam je poznato da je prečnik grafa jednak 3 tako bismo se mogli zaustaviti u ovom trenutku. Ipak, kako su poruke ove iteracije drugačije od poruka prethodne tako algoritam nastavlja sa radom. Poruke pete iteracije su prikazane ispod, koje pri računanju koriste poruke četvrte iteracije kao poruke prethodne iteracije.

$$P_{12} = -0.8$$

$$P_{21} = -4$$

$$P_{23} = -7.5$$

$$P_{32} = -1$$

$$P_{34} = -0.5$$

$$P_{35} = -0.5$$

$$P_{43} = -0.5$$

$$P_{53} = -0.5$$

$$\mu_{12} = 1.5$$

$$\mu_{21} = 0.5$$

$$\mu_{23} = 0.1$$

$$\mu_{32} = 0.5$$

$$\mu_{34} = 3$$

$$\mu_{35} = 1$$

$$\mu_{43} = 4.5$$

$$\mu_{53} = 3.5$$

Sada možemo primjetiti da sve ove poruke su iste kao poruke prethodne iteracije. Ovim završavamo iteriranje kroz postupak i računamo konačnu vrijednost vektora $\mathbf{x}$:

$$\begin{aligned} x_1 &= (P_{11}\mu_{11} + P_{21}\mu_{21})/(P_{11} + P_{21}) = 1/1 = 1 \\ x_2 &= (P_{22}\mu_{22} + P_{12}\mu_{12} + P_{32}\mu_{32})/(P_{22} + P_{12} + P_{32}) = -0.2/0.2 = 1 \\ x_3 &= (P_{33}\mu_{33} + P_{23}\mu_{23} + P_{43}\mu_{43} + P_{53}\mu_{53})/(P_{33} + P_{23} + P_{43} + P_{53}) = 0.75/1.5 = 0.5 \\ x_4 &= (P_{44}\mu_{44} + P_{34}\mu_{34})/(P_{44} + P_{34}) = 3/1.5 = 2 \\ x_5 &= (P_{55}\mu_{55} + P_{35}\mu_{35})/(P_{55} + P_{35}) = 3/1.5 = 2 \end{aligned}$$

Odakle dobijamo konačno rješenje zadatka:

$$\mathbf{x} = \begin{pmatrix} 1 \\ -1 \\ 0.5 \\ 2 \\ 2 \end{pmatrix} \quad (4.9)$$

Za ovo rješenje možemo potvrditi da je tačno jednostavnim množenjem sa lijeve strane sa matricom $\mathbf{A}$, čime dobijamo vektor $\mathbf{b}$:

$$\begin{pmatrix} 5 & 2 & 0 & 0 & 0 \\ 2 & 2 & 3 & 0 & 0 \\ 0 & 3 & 10 & 1 & -1 \\ 0 & 0 & 1 & 2 & 0 \\ 0 & 0 & -1 & 0 & 2 \end{pmatrix} \begin{pmatrix} 1 \\ -1 \\ 0.5 \\ 2 \\ 2 \end{pmatrix} = \begin{pmatrix} 3 \\ 1.5 \\ 2 \\ 4.5 \\ 3.5 \end{pmatrix} \quad (4.10)$$

U prilogu A je pokazan primijenjen algoritam za navedeni primjer u MATLAB programskom okruženju, odakle su se dobile sve numeričke vrijednosti koje su prikazane gore.

U ovom radu je urađen kratak uvod u distribuirane algoritme i Gaussian Belief Propagation algoritam. Nakon toga se obradilo na jednostavan način veza GaBP i nalaženja rješenja sistema linearnih jednačina, te kroz to je urađen jedan jednostavan primjer na kojem se izvršio GaBP algoritam.

Naredni korak, koji bi bio proširenje ovog rada, bi bio implementacija GaBP algoritma tako da postoji mreža koja se sastoji od N čvorova, gdje bi svaki čvor računao vrijednosti poruka od čvorova promjenljivih ka faktor čvorovima i od faktor čvorova ka čvorovima promjenljivih.

Idealno bi bilo, u tom slučaju, da se pored GaBP algoritma na takvu mrežu primijeni i neki od centraliziranih algoritama, kako bi se onda uporedio GaBP algoritam i vidjele njegove prednosti u odnosu na centralizirani algoritam u realnosti.

Postoje mnogi radovi koji se bave ovim problemom na mnogo višem nivou nego ovaj rad i koji su implementirali gore navedeno proširenje analize algoritma, pored čisto matematičke obrade. Pored svega toga, ovaj rad je, za nekoga ko se možda tek susreće sa problemom distribuiranih algoritama i želi više da nauči o njima, dobar početak istraživanja ove problematike. Autor ovog rada se nada da će ovaj rad pomoći drugim studentima koji žele da se bave distribuiranim algoritmima i da će biti korisna startna pozicija takvim studentima.

Prilozi

Prilog A

Implementacija algoritma

```
1 N = 5;
2 A = [5 2 0 0 0 ; 2 2 3 0 0 ; 0 3 10 1 -1 ; 0 0 1 2 0 ; 0 0
      -1 0 2];
3 b = [3 ; 1.5 ; 2 ; 4.5 ; 3.5];
4
5 % Radi jednostavnosti i preglednosti implementacije P i mu
   su
6 % matrice, iako cemo samo pristupati clanovima matrice
7 % koji odgovaraju nenultim poljima matrice A
8
9 P = zeros(N,N);
10 mu = zeros(N,N);
11
12 for i = 1:N
13     P(i,i) = A(i,i);
14     mu(i,i) = b(i) / A(i,i);
15 end
16
17 P_old = P;
18 mu_old = mu;
19
20 % U slucaju stabla, maksimalan potreban broj iteracija je
21 % precnik stabla, sto predstavlja udaljenost dvije
22 % najudaljenije tacke stabla
23
24 eps = 1e-6;
25 max_iter = 20;
26
27 for iter = 1:max_iter
28     for i = 1:N
```

```

29         for j = 1:N
30             if i ~= j && A(i,j) ~= 0
31                 % Racunamo novu vrijednost P_ij na osnovu
32                 % starih vrijednosti P
33                 sum = P_old(i,i);
34                 for k = 1:N
35                     if k ~= i && k ~= j && A(k,i) ~= 0
36                         sum = sum + P_old(k,i);
37                     end
38                 end
39                 P(i,j) = -(A(i,j)^2)/sum;
40
41
42                 % Racunamo novu vrijednost mu_ij na osnovu
43                 % starih vrijednosti P i mu
44                 sum = P_old(i,i)*mu_old(i,i);
45                 for k = 1:N
46                     if k ~= i && k ~= j && A(k,i) ~= 0
47                         sum = sum + P_old(k,i)*mu_old(k,i)
48                         ;
49                     end
50                 end
51                 mu(i,j) = sum/A(i,j);
52             end
53         end
54
55         % Provjera konvergencije
56         if(sumsqr(P - P_old) + sumsqr(mu - mu_old) < eps)
57             break
58         end
59
60         P_old = P;
61         mu_old = mu;
62     end
63
64     P_final = zeros(N,1);

```

```
65 mu_final = zeros(N,1);
66
67 for i = 1:N
68     sum1 = 0;
69     sum2 = 0;
70
71     %      Odvojeno racunamo sume za brojnik i nazivnik
72     %      konacnih vrijednosti vektora srednjih vrijednosti
73
74     for k = 1:N
75         if A(k,i) ~= 0
76             sum1 = sum1 + P(k,i)*mu(k,i);
77             sum2 = sum2 + P(k,i);
78         end
79     end
80
81     mu_final(i) = sum1/sum2;
82     P_final(i) = sum2;
83 end
84
85 if iter == max_iter
86     disp('Algoritam nije konvergirao prije ')
87     disp('dostizanja maksimalnog broja iteracija');
88 end
89
90 % Rjesenje je jednako vektoru srednjih vrijednosti
91 % nakon konvergencije
92
93 P_final;
94 x_final = mu_final
```

Literatura

- [1] J. Du, S. Ma, Y.-C. Wu, S. Kar, and J. M. F. Moura, “Convergence analysis of distributed inference with vector-valued gaussian belief propagation,” *Journal of Machine Learning Research*, vol. 18, no. 1, pp. 6302–6339, 2017.
- [2] D. Bickson, O. Shental, P. Siegel, J. Wolf, and D. Dolev, “Linear detection via belief propagation,” in *Proc. 45th Allerton Conf. on Communications, Control and Computing*, 2007.
- [3] J. Pearl, “Reverend bayes on inference engines: A distributed hierarchical approach,” in *Proceedings of the Second AAAI Conference on Artificial Intelligence*, ser. AAAI’82. AAAI Press, 1982, p. 133–136.
- [4] G. Upton and I. Cook, *A Dictionary of Statistics*. Oxford University Press, 2014.
- [5] Y. Weiss and W. Freeman, “Correctness of belief propagation in gaussian graphical models of arbitrary topology,” *Advances in neural information processing systems*, vol. 12, 1999.
- [6] J. Ortiz, T. Evans, and A. J. Davison, “A visual introduction to gaussian belief propagation,” *arXiv preprint arXiv:2107.02308*, 2021.
- [7] D. Bickson, “Gaussian belief propagation: Theory and application,” *arXiv preprint arXiv:0811.2518*, 2008.